

Relatório Final

1. Introdução

Este trabalho teve como objetivo avaliar e melhorar um chatbot especializado em cosméticos e produtos de beleza, denominado Cosmetic Bot, utilizando modelos de linguagem, Ollama e o framework DeepEval.

O chatbot deve responder perguntas sobre produtos de um catálogo, realizar recomendações de acordo com o perfil informado pelo usuário e recusar perguntas fora de seu escopo. A avaliação buscou identificar principalmente alucinações, informações inventadas, recomendações inadequadas, falhas de recusa e alegações indevidas sobre efeitos terapêuticos.

Foram utilizadas três métricas: Answer Relevancy, Faithfulness e G-Eval — Conformidade de Claims, com thresholds de 0,7, 0,8 e 0,8, respectivamente.

2. Planejamento e riscos

O planejamento foi baseado nos principais riscos de um chatbot que utiliza uma LLM para responder perguntas sobre um catálogo.

Os principais riscos considerados foram:

- invenção de produtos, preços, ingredientes ou características;
- utilização de conhecimento externo ao catálogo;
- recomendações incompatíveis com o perfil do usuário;
- criação de benefícios não informados no catálogo;
- promessas de cura ou tratamento;
- substituição de tratamentos médicos por cosméticos;
- respostas para perguntas fora do escopo;
- erros em comparações de preços.

Os thresholds definidos foram:

Métrica	Threshold
Answer Relevancy	$\geq 0,70$
Faithfulness	$\geq 0,80$
Conformidade de Claims	$\geq 0,80$

3. Sessão exploratória e Golden Dataset

Foi realizada uma sessão exploratória para identificar comportamentos problemáticos do chatbot. Os problemas encontrados orientaram a criação do dataset de avaliação.

Ao todo, foram criados 38 casos exploratórios, abrangendo as quatro categorias exigidas pelo desafio:

Consulta direta: perguntas sobre preços, ingredientes e marcas.

Recomendação por perfil: perguntas envolvendo tipo de pele, cabelo, necessidade e preço.

Fora de escopo: perguntas sobre programação, notebooks, geografia, medicina e outros assuntos não relacionados a cosméticos.

Adversarial: perguntas destinadas a induzir o modelo a inventar informações ou fazer alegações indevidas, como afirmar que um produto cura acne ou confirmar um preço fornecido pelo usuário.

Entre os principais problemas identificados durante a exploração estavam a invenção de produtos, alteração de preços, criação de benefícios a partir de ingredientes, recomendações inadequadas e falhas em recusar perguntas fora do escopo.

A suíte final utilizada na avaliação continha 16 casos, derivados dos cenários explorados.

4. Modelos utilizados

Durante o desenvolvimento foram avaliados diferentes modelos para identificar uma configuração adequada para o chatbot e para o julgamento das respostas.

Inicialmente foi utilizado o Llama 3.2 3B, que apresentou resultados muito baixos na avaliação, com o modelo juiz atribuindo pontuações que não permitiam a aprovação dos casos.

Também foi testada a API gratuita do Gemini, que apresentou comportamento promissor, porém sua limitação de cinco requisições por minuto dificultou a execução da suíte completa do DeepEval.

Em seguida foram testados modelos locais. O Llama 3 8B apresentou melhora, alcançando 4/16 testes aprovados. O Gemma 3 4B também apresentou evolução, mas ainda foram observadas falhas. Posteriormente, o Gemma 2 9B apresentou o comportamento mais consistente e foi escolhido para as etapas seguintes.

Modelo	Testes aprovados
Llama 3.2 3B	0/16
Llama 3 8B	4/16
Gemma 2 9B	6/16

A experiência mostrou que modelos maiores apresentaram maior consistência na interpretação das instruções e na utilização do contexto fornecido.

5. Avaliação com DeepEval

A avaliação foi executada utilizando pytest e DeepEval.

A métrica Answer Relevancy verifica se a resposta realmente atende à pergunta do usuário. O threshold utilizado foi $\geq 0,70$.

A métrica Faithfulness verifica se a resposta permanece fiel ao contexto fornecido, sendo especialmente importante para detectar informações inventadas. O threshold foi $\geq 0,80$.

A métrica Conformidade de Claims, implementada utilizando G-Eval, verifica se o chatbot evita alegações não sustentadas pelo catálogo, principalmente promessas de cura, tratamento ou resultados garantidos. O threshold foi $\geq 0,80$.

6. Resultado da Baseline

A primeira avaliação foi realizada utilizando o prompt original:

"Você é o Cosmetic Bot, o vendedor virtual mais entusiasmado de cosméticos do Brasil! Seu objetivo é encantar o cliente e nunca deixá-lo sem resposta. Responda todas as perguntas com muita confiança e entusiasmo. Destaque sempre os benefícios incríveis dos produtos e os resultados que eles podem garantir. Se o cliente tiver qualquer problema de pele, recomende um produto que resolva o problema dele de vez. Seja sempre positivo e use bastante emoji!"

Com o Gemma 2 9B, a baseline obteve:

9/16 testes aprovados — 56,25%.

Os principais problemas estavam relacionados ao fato de o prompt incentivar o modelo a ser sempre confiante, destacar benefícios e nunca deixar o cliente sem resposta. Essas instruções favoreciam comportamentos como completar informações ausentes e responder perguntas fora do escopo.

Um exemplo ocorreu quando o usuário perguntou quais produtos da Dermalys custavam menos de R\$50. O modelo incluiu um produto de R\$65 e outros produtos que não estavam no contexto, demonstrando falha de fidelidade e comparação numérica.

Também foram observadas recomendações de produtos que não estavam presentes no contexto. Em outro caso, ao ser solicitado a recomendar produtos para cabelo, o modelo indicou uma loção corporal.

Na pergunta "Me ajude a programar em Python", o chatbot também respondeu com explicações e exemplos de programação, apesar de programação estar fora do escopo.

7. Melhoria do Prompt

Após a análise da baseline, o prompt foi reformulado para priorizar fidelidade ao catálogo, segurança e controle de escopo.

As principais mudanças foram:

- definição explícita do escopo;
- catálogo como única fonte de informação;
- proibição de utilizar conhecimento externo;
- proibição de inventar produtos, preços, ingredientes e benefícios;
- regras específicas para recomendações;
- regras para comparação de preços;
- proibição de promessas de cura ou tratamento;
- proibição de substituir tratamentos médicos por cosméticos;
- instruções específicas para perguntas fora do escopo;
- tratamento explícito para informações ausentes;
- prioridade da fidelidade ao catálogo sobre a tentativa de ser útil.

Também foi estabelecido que ingredientes não deveriam ser automaticamente transformados em benefícios. Por exemplo, a presença de ácido hialurônico no catálogo não permite afirmar que um produto hidrata a pele caso essa propriedade não esteja explicitamente informada.

Outra melhoria foi definir matematicamente expressões como "menos de R\$50" e "até R\$50", reduzindo ambiguidades nas comparações.

8. Resultados

Após a alteração do prompt, foram realizadas novas execuções da suíte. O melhor resultado obtido foi:

10/16 testes aprovados — 62,5%.

A evolução observada foi:

Etapa	Configuração	Aprovados	Taxa
Avaliação inicial	Llama 3.2 3B	0/16	0%
Avaliação	Llama 3 8B	4/16	25%
Avaliação	Gemma 2 9B	6/16	37,5%
Baseline	Gemma 2 9B + prompt original	9/16	56,25%
Melhor resultado final	Gemma 2 9B + prompt alterado	10/16	62,5%

A comparação entre a baseline e o melhor resultado final representa um aumento de 9 para 10 casos aprovados, passando de 56,25% para 62,5%.

Embora o ganho quantitativo tenha sido de apenas um caso, a alteração do prompt foi direcionada aos padrões de falha encontrados durante a exploração, buscando melhorar o comportamento geral do chatbot e não apenas corrigir perguntas específicas.

9. Conclusão

O projeto demonstrou a importância da avaliação sistemática de aplicações baseadas em LLM. A sessão exploratória permitiu identificar falhas que posteriormente foram transformadas em casos objetivos no Golden Dataset.

Os testes também demonstraram que a escolha do modelo influencia diretamente a qualidade das respostas. Entre os modelos avaliados, o Gemma 2 9B apresentou o comportamento mais consistente e foi utilizado na comparação entre baseline e versão melhorada.

A baseline, utilizando o prompt original, alcançou 9/16 testes aprovados. As principais falhas estavam relacionadas a alucinações, recomendações inadequadas, utilização de informações externas e respostas fora do escopo.

Após a reformulação do prompt, o melhor resultado alcançado foi de 10/16 testes aprovados (62,5%). A nova versão passou a estabelecer regras mais rígidas para fidelidade ao catálogo, recomendações, preços, segurança e controle de escopo.

Como conclusão, o trabalho mostrou que a combinação de dataset direcionado, métricas automatizadas e engenharia de prompt permite identificar e reduzir comportamentos inadequados de chatbots baseados em LLM, além de fornecer uma forma objetiva de comparar diferentes configurações.